

FRAUDSHIELD AI

Application web de détection de fraude bancaire par intelligence artificielle

Rapport technique et scientifique

Projet réalisé avec Python, Streamlit et Machine Learning

Année académique 2025-2026

Auteur : MAMPOUYA CLARK Chancy Loïc Franlly

Résumé

Ce projet présente FraudShield AI, une application web professionnelle destinée à l'analyse de profils bancaires et à la détection automatisée de risques par intelligence artificielle. L'application combine une classification supervisée, une détection non supervisée d'anomalies, une matrice de corrélation, une matrice de confusion, des courbes ROC, un scoring individuel et des exports opérationnels. Le jeu de données fourni comporte 10 000 clients et 12 variables. Sa cible initiale, churn, est utilisée dans le cadre pédagogique comme classe binaire de risque. Cette convention est explicitement documentée afin de conserver la transparence scientifique.

Le meilleur modèle obtenu est Gradient Boosting, avec une ROC-AUC de 0.877, une exactitude de 0.873, une précision de 0.800, un rappel de 0.503 et un F1-score de 0.618.

Abstract

This report presents FraudShield AI, a professional Streamlit web application for AI-assisted banking risk detection. It combines supervised classification, unsupervised anomaly detection, correlation analysis, confusion matrix, ROC curves, individual scoring, batch scoring, and report exports. The supplied dataset contains 10,000 customer records. For pedagogical purposes, its original churn target is treated as a binary risk label, while this limitation is clearly disclosed.

Table des matières

1. Introduction
2. Contexte et problématique
3. Objectifs
4. Étude des données
5. Méthodologie
6. Modélisation et résultats
7. Conception de l’application
8. Fonctionnalités
9. Sécurité et limites
10. Déploiement
11. Conclusion et perspectives

1. Introduction

La fraude bancaire représente un enjeu majeur pour les établissements financiers. L'augmentation du volume de données et la complexité des comportements rendent les contrôles exclusivement manuels insuffisants. L'intelligence artificielle permet de détecter des configurations inhabituelles, de prioriser les dossiers et de produire un score de risque exploitable par un analyste.

FraudShield AI a été conçu comme une plateforme d'aide à la décision. Il ne remplace pas l'expertise humaine : il concentre l'attention sur les cas à examiner et fournit des indicateurs explicables.

2. Contexte et problématique

La problématique retenue est la suivante : comment construire une application web interactive capable d'exploiter des données bancaires, d'entraîner plusieurs modèles de classification, de visualiser les corrélations, d'évaluer les prédictions avec une matrice de confusion et d'identifier des profils atypiques susceptibles de constituer des alertes ?

3. Objectifs

• Centraliser et contrôler la qualité des données.

• Analyser les relations entre variables grâce à une matrice de corrélation.

• Comparer plusieurs algorithmes de Machine Learning.

• Évaluer les modèles avec Accuracy, précision, rappel, F1-score, ROC-AUC et matrice de confusion.

• Détecter les anomalies avec Isolation Forest.

• Permettre la prédiction en temps réel et le scoring par lot.

• Exporter les résultats en CSV et PDF.

4. Présentation du jeu de données

Le dataset contient 10,000 observations et 12 colonnes. La variable cible est binaire. La classe 1 représente 20.37 % des observations, contre 79.63 % pour la classe 0.

Variable	Type	Interprétation
customer_id	int64	Identifiant unique
credit_score	int64	Score de crédit
country	object	Pays
gender	object	Genre
age	int64	Âge
tenure	int64	Ancienneté bancaire
balance	float64	Solde du compte
products_number	int64	Nombre de produits
credit_card	int64	Possession d'une carte
active_member	int64	Client actif
estimated_salary	float64	Salaire estimé

churn	int64	Classe binaire de risque pédagogique

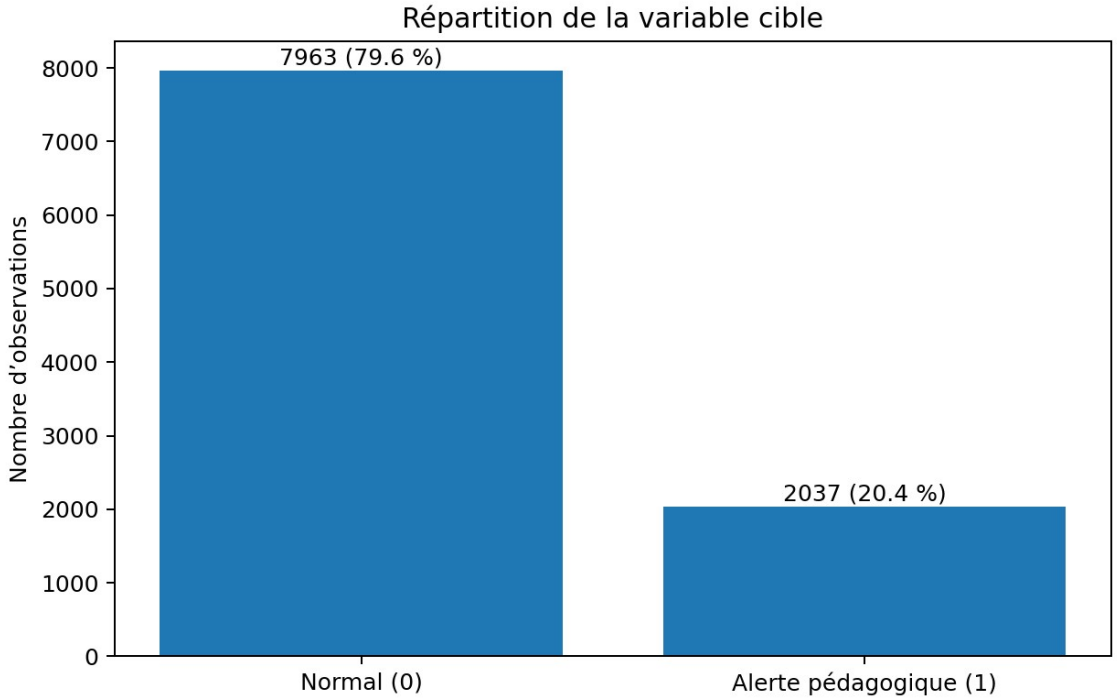


Figure 1 - Répartition de la variable cible

5. Analyse exploratoire

5.1 Matrice de corrélation

La corrélation de Pearson mesure la force et le sens d'une relation linéaire entre deux variables numériques. Une valeur proche de 1 indique une association positive forte, une valeur proche de -1 une association négative forte, et une valeur proche de 0 une faible relation linéaire. La corrélation ne doit pas être interprétée comme une causalité.

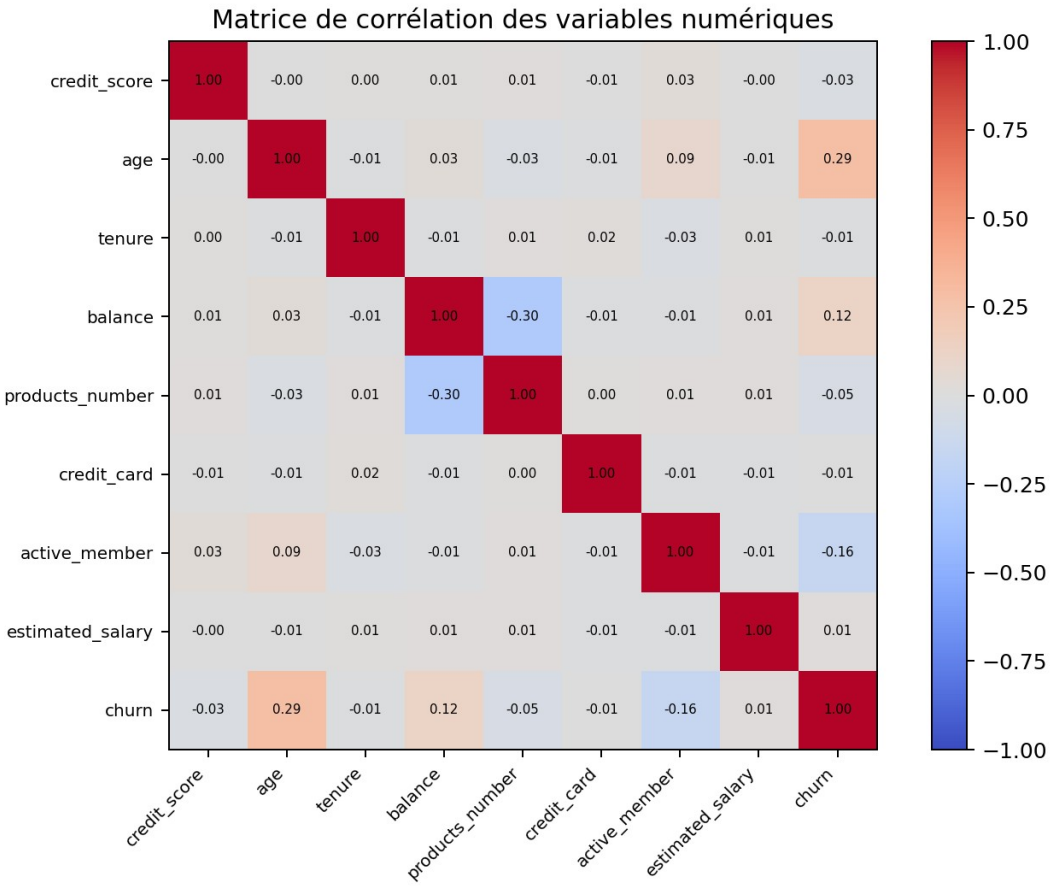


Figure 2 - Matrice de corrélation

5.2 Prétraitement

Le pipeline automatise l'imputation des valeurs manquantes, la standardisation des variables numériques et l'encodage One-Hot des variables catégorielles. La séparation apprentissage/test est stratifiée : 75 % des données sont utilisées pour l'apprentissage et 25 % pour l'évaluation.

6. Modélisation

Trois modèles ont été comparés : régression logistique, Random Forest et Gradient Boosting. La sélection finale repose principalement sur la ROC-AUC, complétée par le rappel et le F1-score.

Modèle	Accuracy	Précision	Rappel	F1-score	ROC-AUC
Gradient Boosting	0.873	0.800	0.503	0.618	0.877
Random Forest	0.847	0.624	0.625	0.624	0.871
Régression logistique	0.720	0.397	0.721	0.512	0.787

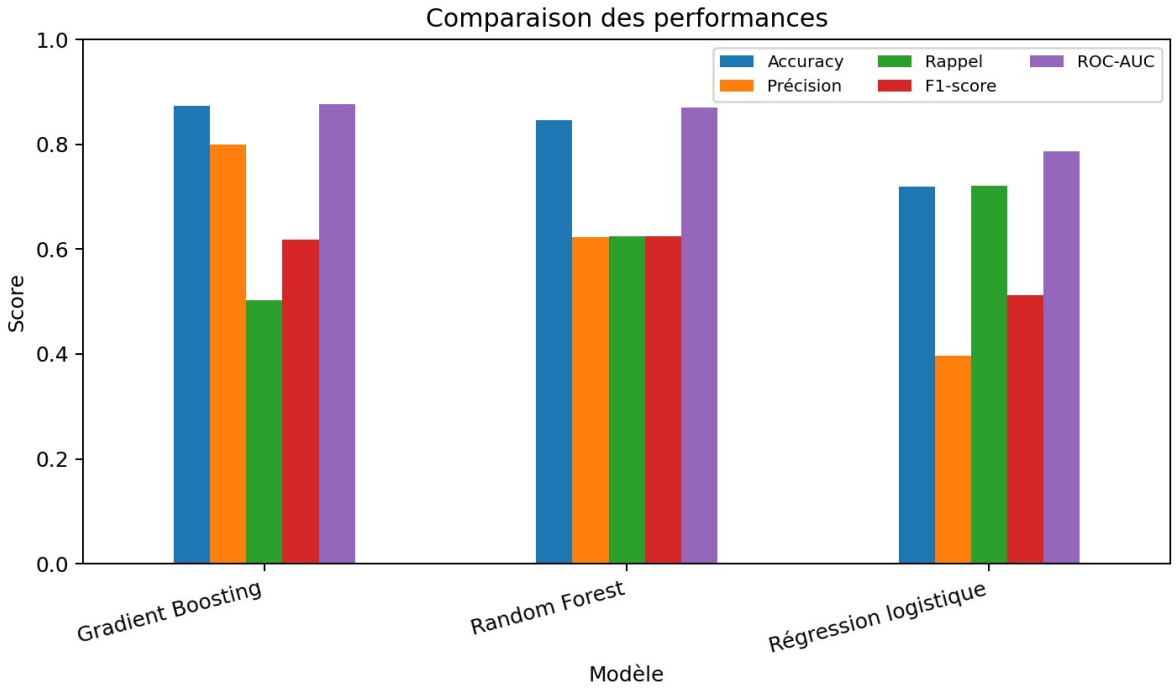


Figure 3 - Comparaison des modèles

6.1 Matrice de confusion

La matrice de confusion synthétise quatre situations : vrais négatifs, faux positifs, faux négatifs et vrais positifs. Dans un contexte de fraude, les faux négatifs sont particulièrement sensibles, car ils représentent des cas réellement à risque que le modèle n'a pas détectés.

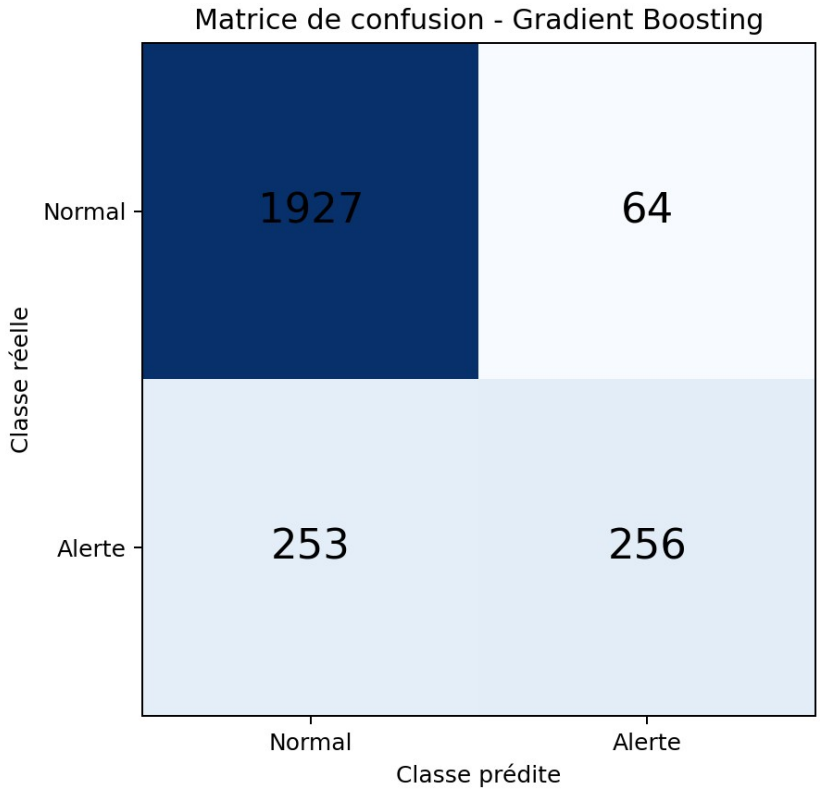


Figure 4 - Matrice de confusion du modèle Gradient Boosting

Sur l'échantillon test, le modèle produit 1927 vrais négatifs, 64 faux positifs, 253 faux négatifs et 256 vrais positifs.

6.2 Courbe ROC

La courbe ROC analyse le compromis entre taux de vrais positifs et taux de faux positifs pour différents seuils. Une aire sous la courbe proche de 1 correspond à une bonne capacité de discrimination.

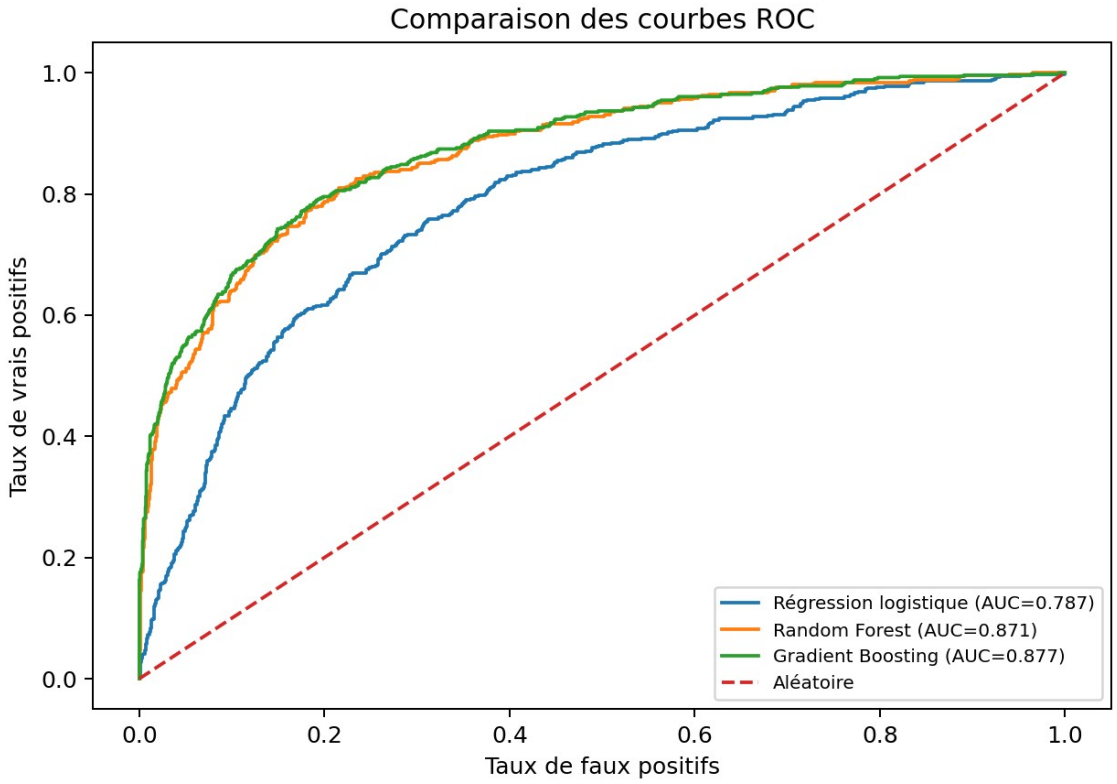


Figure 5 - Courbes ROC des modèles

6.3 Importance des variables

L'importance par permutation mesure la dégradation de la ROC-AUC lorsque les valeurs d'une variable sont mélangées. Elle offre une lecture globale de l'influence prédictive des variables.

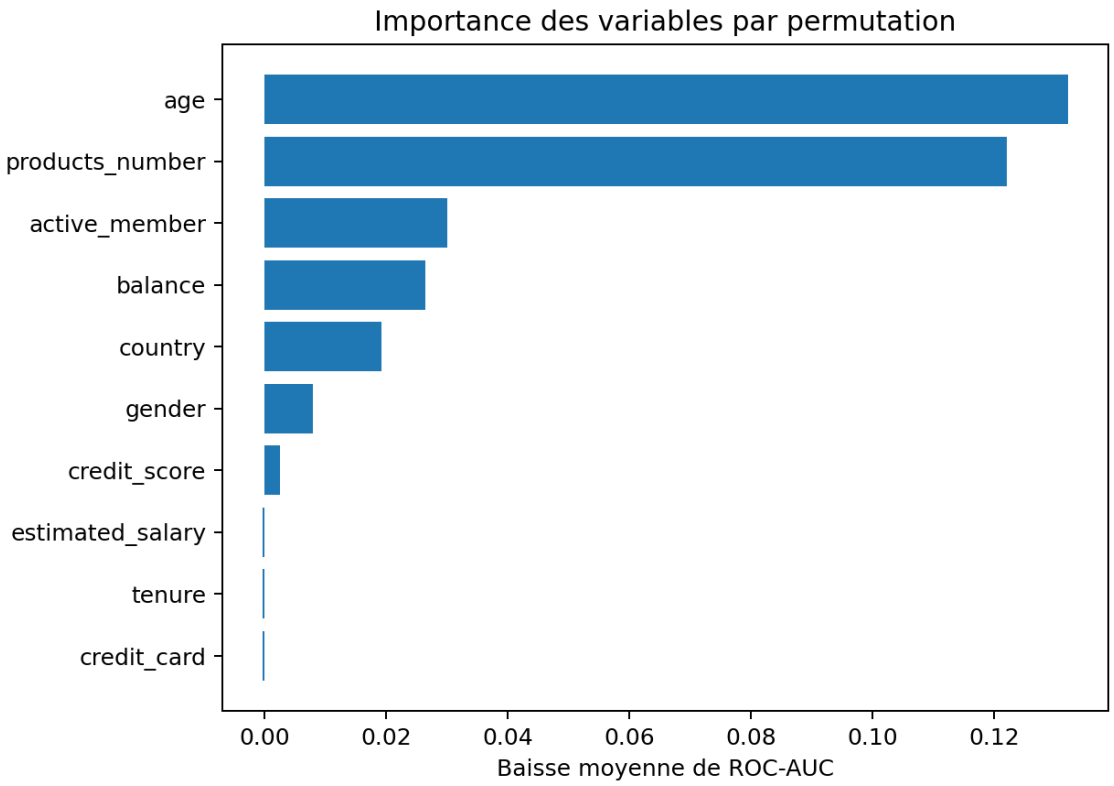


Figure 6 - Importance des variables

7. Détection non supervisée d'anomalies

Isolation Forest est utilisé pour détecter les profils atypiques sans nécessiter d'étiquette de fraude. L'algorithme isole rapidement les observations rares dans l'espace des variables. Un taux de contamination de 5 % est retenu pour générer une liste prioritaire de dossiers à examiner.

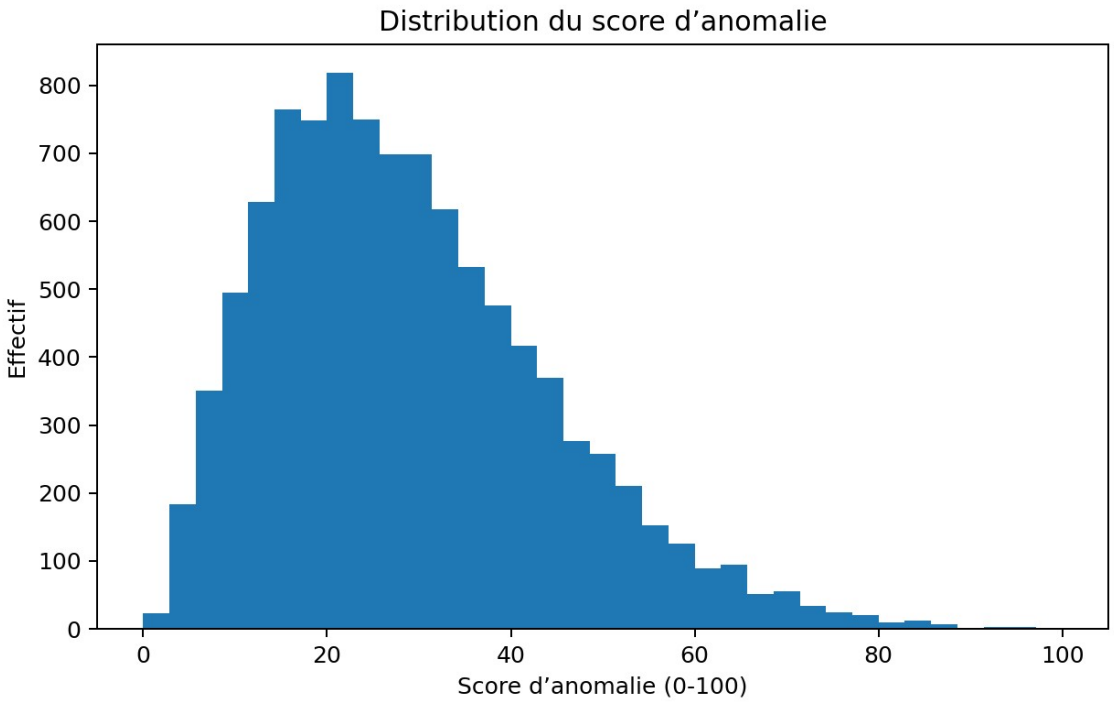


Figure 7 - Distribution du score d'anomalie

L'algorithme a signalé 500 profils atypiques sur 10000 clients. Ces alertes ne constituent pas une preuve de fraude : elles sont destinées à déclencher une vérification humaine.

8. Architecture de l'application

L'application suit une architecture en couches : interface Streamlit, couche de traitement Pandas, pipeline Scikit-learn, moteur de visualisation Plotly et module d'export. Les objets entraînés peuvent être sérialisés avec Joblib.

Interface	Streamlit : navigation, formulaires, dashboard
Données	Pandas : import, nettoyage, validation
Machine Learning	Scikit-learn : pipelines, modèles et métriques
Visualisation	Plotly : graphiques interactifs
Exports	CSV et rapport PDF automatisé

9. Fonctionnalités principales

Dashboard exécutif

KPI, répartition des classes, scores d'anomalie et profils prioritaires.

Import et qualité

Contrôle des colonnes, valeurs manquantes, doublons et aperçu.

Corrélation
Heatmap interactive avec coefficients.

Entraînement ML
Comparaison automatisée de trois algorithmes.

Évaluation
Matrice de confusion, courbe ROC et métriques.

Prédiction temps réel
Formulaire individuel et jauge de score de risque.

Scoring par lot
Traitement d'un fichier CSV complet.

Rapports
Téléchargement PDF et export des alertes.

10. Sécurité, éthique et limites
Une application bancaire réelle doit intégrer l'authentification forte, le chiffrement, une journalisation d'audit, une gestion stricte des droits, l'anonymisation des données et un suivi de la dérive du modèle. Les décisions à fort impact doivent rester soumises à une validation humaine.

Limite majeure : le dataset fourni est originellement un dataset de churn client et non un historique de transactions frauduleuses. Dans ce travail pédagogique, la cible est assimilée à une classe de risque afin de répondre aux exigences fonctionnelles. Pour une mise en production, il est indispensable de disposer d'un dataset transactionnel étiqueté fraude/non-fraude.

11. Installation et déploiement
1. Installer Python 3.10 ou supérieur.
2. Ouvrir un terminal dans le dossier du projet.
3. Exécuter : pip install -r requirements.txt
4. Lancer : streamlit run app.py
5. Pour Streamlit Community Cloud, déposer le projet sur GitHub puis sélectionner app.py comme fichier principal.

12. Conclusion et perspectives
FraudShield AI démontre la faisabilité d'une plateforme complète d'analyse de risque bancaire. Le meilleur modèle, Gradient Boosting, atteint une ROC-AUC de 0.877. L'application répond aux attentes pédagogiques : corrélation, matrice de confusion, comparaison de modèles, scoring et détection d'anomalies.

Les évolutions prioritaires sont l'intégration d'un vrai dataset transactionnel, la gestion du déséquilibre avec SMOTE ou des pertes pondérées, l'explicabilité locale avec SHAP, une base de données d'historique, une authentification par rôles et un système d'alertes en temps réel.

Bibliographie

• Breiman, L. (2001). Random Forests. Machine Learning, 45, 5-32.

• Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. ICDM.

• Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.

• Streamlit Documentation. Building interactive data applications with Python.

Annexe - Structure du projet

```
BankFraud_AI_Professional/
├── app.py
├── requirements.txt
├── README.md
├── data/bank_dataset.csv
├── models/bank_fraud_risk_model.joblib
├── assets/ (figures)
├── exports/ (résultats)
└── reports/ (rapport Word et PDF)
```